


▼ Jak przetwarza tekst AI? 🤖



Na dzisiejszych zajęciach zajmujemy się tokenizacją, czyli zamianą tekstu na tokeny.

Token to najmniejsza jednostka tekstu, którą model „rozumie” i przetwarza.

▼ W jaki sposób tokenizujemy?

Możemy dzielić:

- na słowa
- na zdania
- na morfem
 - Morfem to najmniejsza cząstka języka, która ma jakieś znaczenie.
 - słowo **domki**
 - dom → znaczy „budynek, w którym się mieszka”
 - -ek → oznacza zdrobnienie („mały dom”)
 - -i → końcówka liczby mnogiej
- na znaki
 - ale czy warto?

▼ Przykład tokenizacji

```
!pip install nltk==3.8.1
```

```
Collecting nltk==3.8.1
  Downloading nltk-3.8.1-py3-none-any.whl.metadata (2.8 kB)
Requirement already satisfied: click in /usr/local/lib/python3.13/dist-packages (from nltk==3.8.1) (8.5.0)
Requirement already satisfied: joblib in /usr/local/lib/python3.13/dist-packages (from nltk==3.8.1) (1.6.0)
Requirement already satisfied: regex>=2021.8.3 in /usr/local/lib/python3.13/dist-packages (from nltk==3.8.1) (2025.11.3)
Requirement already satisfied: tqdm in /usr/local/lib/python3.13/dist-packages (from nltk==3.8.1) (4.67.3)
Requirement already satisfied: cloudpickle>=3.0 in /usr/local/lib/python3.13/dist-packages (from joblib->nltk==3.8.1) (3.1.2)
Downloading nltk-3.8.1-py3-none-any.whl (1.5 MB)
----- 1.5/1.5 MB 18.7 MB/s eta 0:00:00
Installing collected packages: nltk
  Attempting uninstall: nltk
    Found existing installation: nltk 3.9.1
    Uninstalling nltk-3.9.1:
      Successfully uninstalled nltk-3.9.1
ERROR: pip's dependency resolver does not currently take into account all the packages that are installed. This behaviour is
textblob 0.19.0 requires nltk>=3.9, but you have nltk 3.8.1 which is incompatible.
Successfully installed nltk-3.8.1
```

```
# NLTK (Natural Language Toolkit) - biblioteka z której skorzystamy
import nltk
from nltk.tokenize import word_tokenize, sent_tokenize
from nltk.util import ngrams

nltk.download('punkt')
tekst = "Domki są piękne. Mam kilka domków w mojej wiosce."
```

```
# 1. Tokenizacja na zdania
zdania = sent_tokenize(tekst, language='polish')
print("Tokenizacja na zdania:")
print(zdania)
print()

# 2. Tokenizacja na słowa
slova = word_tokenize(tekst, language='polish')
print("Tokenizacja na słowa:")
print(slova)
print()

# 3. Tokenizacja na morfemy (przykład uproszczony)
# Podział słowa "domki" na morfemy: dom-ek-i
# (w praktyce do morfemów używa się bibliotek)
morfemy = {
    "domki": ["dom", "-ek", "-i"],
    "piękne": ["piękn-", "-e"],
    "są": ["być"],
}
print("Przykład tokenizacji na morfemy:")
for slowo, czesci in morfemy.items():
    print(f"{slowo} -> {czesci}")
print()

# 4. Tokenizacja na znaki
znaki = list(tekst)
print("Tokenizacja na znaki:")
print(znaki)
print("Bez powtórzeń:")
print(set(znaki))
```

[nltk_data] Downloading package punkt to /root/nltk_data...

[nltk_data] Unzipping tokenizers/punkt.zip.

Tokenizacja na zdania:

['Domki są piękne.', 'Mam kilka domków w mojej wiosce.']

Tokenizacja na słowa:

['Domki', 'są', 'piękne', '.', 'Mam', 'kilka', 'domków', 'w', 'mojej', 'wiosce', '.']

Przykład tokenizacji na morfemy:

domki -> ['dom', '-ek', '-i']

piękne -> ['piękn-', '-e']

są -> ['być']

Tokenizacja na znaki:

['D', 'o', 'm', 'k', 'i', ' ', 's', 'ą', ' ', 'p', 'i', 'ę', 'k', 'n', 'e', '.', ' ', 'M', 'a', 'm', ' ', 'k', 'i', 'l', 'k', 'a', ' ', 'd', 'o', 'm', 'k', 'ó', 'w', ' ', 'w', ' ', 'm', 'o', 'j', 'e', 'j', ' ', 'w', 'i', 'o', 's', 'c', 'e', '.']

Bez powtórzeń:

{'k', 'ą', 'd', 'w', 'l', 'i', 'm', 'ó', 'ę', '.', 's', 'p', 'e', 'M', 'a', 'n', 'c', 'D', ' ', 'o', 'j'}

▼ Słownik

Słownik to zbiór wszystkich tokenów, które model „zna” i potrafi rozpoznać.

Co jeśli w tekście jest słowo którego nie ma w słowniku modelu?

To problem **Out-Of-Vocabulary**. 🤖

- Podzielmy słowa na podśłowa które model zna (np WordPiece wykorzystywane przez BERT). To subword tokenization
- Traktujemy każdy znak jako token
 - Plus: znamy wszystkie litery jakie mogą się pojawić
 - Minus: powoduje to bardzo długie sekwencje tokenów, np litera 'c' nic nie wnosi do sensu zdania
- Dodajmy nowe słowa w trakcie treningu lub użycia
- Zastępowanie rzadkich słów tokenem 'UNK' (unknown) – dla nieznanych słów.

Stopword to słowo, które nie niesie dużej treści semantycznej.

Przykład: "i", "na", "że", "the", "is", "of"

ALE! Znaki interpunkcyjne oraz emotikony mogą nieść znaczenie semantyczne! 😊🥰👉

▼ Przykład

```
!pip install transformers
```

Requirement already satisfied: transformers in /usr/local/lib/python3.13/dist-packages (5.18.0)

Requirement already satisfied: huggingface-hub<3.0, >=1.31.0 in /usr/local/lib/python3.13/dist-packages (from transformers) (1.31.0)

Requirement already satisfied: numpy>=1.17 in /usr/local/lib/python3.13/dist-packages (from transformers) (2.1.3)
 Requirement already satisfied: packaging>=20.0 in /usr/local/lib/python3.13/dist-packages (from transformers) (26.3)
 Requirement already satisfied: pyyaml>=5.1 in /usr/local/lib/python3.13/dist-packages (from transformers) (6.0.3)
 Requirement already satisfied: regex>=2025.10.22 in /usr/local/lib/python3.13/dist-packages (from transformers) (2025.11.3)
 Requirement already satisfied: tokenizers<0.24.0,>=0.23.1 in /usr/local/lib/python3.13/dist-packages (from transformers) (0.20.1)
 Requirement already satisfied: typer in /usr/local/lib/python3.13/dist-packages (from transformers) (0.27.2)
 Requirement already satisfied: safetensors>=0.8.0 in /usr/local/lib/python3.13/dist-packages (from transformers) (0.8.0)
 Requirement already satisfied: tqdm>=4.60 in /usr/local/lib/python3.13/dist-packages (from transformers) (4.67.3)
 Requirement already satisfied: click<9.0.0,>=8.4.2 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.0.0) (8.1.8)
 Requirement already satisfied: filelock>=3.10.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.0.0) (3.16.1)
 Requirement already satisfied: fsspec>=2023.5.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.0.0) (2025.10.2)
 Requirement already satisfied: hf-xet<2.0.0,>=1.6.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.0.0) (1.2.0)
 Requirement already satisfied: httpx<1,>=0.23.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.0.0) (0.27.2)
 Requirement already satisfied: typing-extensions>=4.1.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.0.0) (4.12.0)
 Requirement already satisfied: shellingham>=1.3.0 in /usr/local/lib/python3.13/dist-packages (from typer->transformers) (1.5.4)
 Requirement already satisfied: rich>=13.8.0 in /usr/local/lib/python3.13/dist-packages (from typer->transformers) (13.9.4)
 Requirement already satisfied: annotated-doc>=0.0.2 in /usr/local/lib/python3.13/dist-packages (from typer->transformers) (0.0.2)
 Requirement already satisfied: anyio in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.0.0) (4.6.2)
 Requirement already satisfied: certifi in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.0.0) (2025.10.2)
 Requirement already satisfied: httpcore==1.* in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.0.0) (1.0.7)
 Requirement already satisfied: idna in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.0.0) (3.10.1)
 Requirement already satisfied: h11>=0.16 in /usr/local/lib/python3.13/dist-packages (from httpcore==1.*->httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.0.0) (0.14.0)
 Requirement already satisfied: markdown-it-py>=2.2.0 in /usr/local/lib/python3.13/dist-packages (from rich>=13.8.0->typer->transformers) (3.0.0)
 Requirement already satisfied: pygments<3.0.0,>=2.13.0 in /usr/local/lib/python3.13/dist-packages (from rich>=13.8.0->typer->transformers) (2.18.0)
 Requirement already satisfied: mdurl~=0.1 in /usr/local/lib/python3.13/dist-packages (from markdown-it-py>=2.2.0->rich>=13.8.0->typer->transformers) (0.1.2)

```
from transformers import BertTokenizer
```

```
tokenizer = BertTokenizer.from_pretrained('bert-base-uncased')
tekst = "Serki są smaczne i pachnące 🍷"
```

```
# Tokenizacja na subwordy
tokens = tokenizer.tokenize(tekst)
print("Subword tokeny:")
print(tokens)
```

```
# Pokazanie, które tokeny są OOV (są dzielone na mniejsze części)
for t in tokens:
    if t.startswith("##"):
        print(f"Fragment subword (OOV część): {t}")
```

```
tokenizer_config.json: 100%
```

```
48.0/48.0 [00:00<00:00, 348B/s]
```

```
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and fast
WARNING:huggingface_hub.utils._http:Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to
```

```
vocab.txt: 100%
```

```
232k/232k [00:00<00:00, 1.95MB/s]
```

```
tokenizer.json: 100%
```

```
466k/466k [00:00<00:00, 1.98MB/s]
```

```
Subword tokeny:
```

```
['ser', '##ki', 'sa', 'sm', '##ac', '##z', '##ne', 'i', 'pac', '##hn', '##ace', '[UNK]']
```

```
Fragment subword (OOV część): ##ki
```

```
Fragment subword (OOV część): ##ac
```

```
Fragment subword (OOV część): ##z
```

```
Fragment subword (OOV część): ##ne
```

```
Fragment subword (OOV część): ##hn
```

```
Fragment subword (OOV część): ##ace
```

✓ Pre-processing

Podczas pre-processingu możemy:

- castować do małych liter
- usuwać specjalne litery (np ą, ü)
- usuwać znaki specjalne (np "™")

✓ Przykład

```
!pip install unidecode
```

```
Collecting unidecode
```

```
Downloading Unidecode-1.4.0-py3-none-any.whl.metadata (13 kB)
```

```
Downloading Unidecode-1.4.0-py3-none-any.whl (235 kB)
```

```
235.8/235.8 kB 3.9 MB/s eta 0:00:00
```

```
Installing collected packages: unidecode
```

```
Successfully installed unidecode-1.4.0
```

```
# Przykładowy tekst
```

```
tekst = "Domki są piękne™ i wyjątkowe ü!"
```

```
print("Oryginalne zdanie: ", tekst)
```

```
# 1. Castowanie do małych liter
tekst_lower = tekst.lower()
print("Małe litery:", tekst_lower)

# 2. Usuwanie znaków diakrytycznych (np. å, ü)
import unicodedata
tekst_ascii = unicodedata.unidecode(tekst_lower)
print("Bez znaków diakrytycznych:", tekst_ascii)

# 3. Usuwanie znaków specjalnych (np. ", !, ?)
import re
tekst_clean = re.sub(r'[\W\s]', '', tekst_ascii)
print("Bez znaków specjalnych:", tekst_clean)
```

```
Oryginalne zdanie: Domki są piękne i wyjątkowe ü!
Małe litery: domki są piękne i wyjątkowe ü!
Bez znaków diakrytycznych: domki sa piekne(tm) i wyjątkowe u!
Bez znaków specjalnych: domki sa pieknetm i wyjątkowe u
```

Teraz trochę praktyki...

Instalujemy potrzebną bibliotekę - o samych transformerach będzie więcej później 🐼

```
!pip install transformers
```

```
Requirement already satisfied: transformers in /usr/local/lib/python3.13/dist-packages (5.18.0)
Requirement already satisfied: huggingface-hub<3.0,>=1.31.0 in /usr/local/lib/python3.13/dist-packages (from transformers) (1.31.0)
Requirement already satisfied: numpy>=1.17 in /usr/local/lib/python3.13/dist-packages (from transformers) (2.1.3)
Requirement already satisfied: packaging>=20.0 in /usr/local/lib/python3.13/dist-packages (from transformers) (26.3)
Requirement already satisfied: pyyaml>=5.1 in /usr/local/lib/python3.13/dist-packages (from transformers) (6.0.3)
Requirement already satisfied: regex>=2025.10.22 in /usr/local/lib/python3.13/dist-packages (from transformers) (2025.11.3)
Requirement already satisfied: tokenizers<0.24.0,>=0.23.1 in /usr/local/lib/python3.13/dist-packages (from transformers) (0.23.1)
Requirement already satisfied: typer in /usr/local/lib/python3.13/dist-packages (from transformers) (0.27.2)
Requirement already satisfied: safetensors>=0.8.0 in /usr/local/lib/python3.13/dist-packages (from transformers) (0.8.0)
Requirement already satisfied: tqdm>=4.60 in /usr/local/lib/python3.13/dist-packages (from transformers) (4.67.3)
Requirement already satisfied: click<9.0.0,>=8.4.2 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.31.0) (8.4.2)
Requirement already satisfied: filelock>=3.10.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.31.0) (3.10.0)
Requirement already satisfied: fsspec>=2023.5.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.31.0) (2023.5.0)
Requirement already satisfied: hf-xet<2.0.0,>=1.6.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.31.0) (1.6.0)
Requirement already satisfied: httpx<1,>=0.23.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.31.0) (0.23.0)
Requirement already satisfied: typing-extensions>=4.1.0 in /usr/local/lib/python3.13/dist-packages (from huggingface-hub<3.0,>=1.31.0) (4.1.0)
Requirement already satisfied: shellingham>=1.3.0 in /usr/local/lib/python3.13/dist-packages (from typer->transformers) (1.5.0)
Requirement already satisfied: rich>=13.8.0 in /usr/local/lib/python3.13/dist-packages (from typer->transformers) (13.9.4)
Requirement already satisfied: annotated-doc>=0.0.2 in /usr/local/lib/python3.13/dist-packages (from typer->transformers) (0.0.2)
Requirement already satisfied: anyio in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.31.0) (3.5.0)
Requirement already satisfied: certifi in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.31.0) (2025.11.12)
Requirement already satisfied: httpcore==1.* in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.31.0) (1.0.7)
Requirement already satisfied: idna in /usr/local/lib/python3.13/dist-packages (from httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.31.0) (3.10.1)
Requirement already satisfied: h11>=0.16 in /usr/local/lib/python3.13/dist-packages (from httpcore==1.*->httpx<1,>=0.23.0->huggingface-hub<3.0,>=1.31.0) (0.16.0)
Requirement already satisfied: markdown-it-py>=2.2.0 in /usr/local/lib/python3.13/dist-packages (from rich>=13.8.0->typer->transformers) (3.0.0)
Requirement already satisfied: pygments<3.0.0,>=2.13.0 in /usr/local/lib/python3.13/dist-packages (from rich>=13.8.0->typer->transformers) (2.19.1)
Requirement already satisfied: mdurl~=0.1 in /usr/local/lib/python3.13/dist-packages (from markdown-it-py>=2.2.0->rich>=13.8.0->typer->transformers) (0.1.2)
```

Wybieramy model - każdy model ma swój tokenizer

```
from transformers import AutoTokenizer

# Wybieramy tokenizer dla wybranego modelu z HF
tokenizer = AutoTokenizer.from_pretrained("bert-base-uncased")
```

```
config.json: 100%
```

```
570/570 [00:00<00:00, 14.5kB/s]
```

Wybieramy tekst, który chcemy ztokenizować

```
text = "Kocham ser."
```

Używamy gotowej metody! 🐼

```
.tokenize()
```

podzieli nam tekst na tokeny.

```
# Podział tekstu na tokeny
tokens = tokenizer.tokenize(text)
print("Tokeny:", tokens)
```

```
Tokeny: ['koch', '##am', 'ser', '.']
```

Chwila, chwila, a co to za "##am"? W taki sposób BERT oznaczył sobie kontynuację słowa -> am jest końcówką koch.

Ale chwila, model nadal tego nie zrozumie - musimy zamienić nasze tokeny na reprezentacje cyfrowe

```
token_ids = tokenizer.convert_tokens_to_ids(tokens)
print("Tokeny w formie ID:", token_ids)
```

```
Tokeny w formie ID: [15259, 3286, 14262, 1012]
```

Przygotujmy od razu cały słownik wejściowy dla modelu - przyda się w przyszłości:

```
encoded_input = tokenizer(text, return_tensors="pt") # return_tensors="pt" - zamieniamy listy na tensory PyTorch
print("Słownik z inputem dla modelu:")
print(encoded_input)
```

```
Słownik z inputem dla modelu:
{'input_ids': tensor([[ 101, 15259, 3286, 14262, 1012, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0]]), 'attention_mask': tensor([[1, 1, 1, 1, 1, 1]])}
```

Na co patrzymy?

```
{
  'input_ids': tensor([[101, 15259, 3286, 14262, 1012, 102]]),
  'token_type_ids': tensor([[0, 0, 0, 0, 0, 0]]),
  'attention_mask': tensor([[1, 1, 1, 1, 1, 1]])
}
```

- 'input_ids' - to właśnie nasze tokeny, to ten sam wynik co z poprzedniego kroku: `tokenizer.convert_tokens_to_ids(tokens)`
 - Dodatkowe tokeny 101 (początek sekwencji) i 102 (koniec sekwencji) to specjalne tokeny modelu BERT - więcej o specjalnych tokenach dowiesz się na wykładzie
- 'token_type_ids' - wskazuje, do której sekwencji należy token (mamy tylko jeden tekst więc same 0)
- 'attention_mask' - Mówi modelowi, które tokeny są „istotne” (1), a które to padding (0).
 - nie dodaliśmy paddingu

✓ Inne przykłady

✓ A jak to wygląda z innym modelem?

```
from transformers import AutoTokenizer

tokenizer = AutoTokenizer.from_pretrained("distilbert-base-uncased")

text = "Często jem goudę."
tokens = tokenizer.tokenize(text)
token_ids = tokenizer.convert_tokens_to_ids(tokens)
encoded_input = tokenizer(text, return_tensors="pt")

print("Tokeny:", tokens)
print("Tokeny w formie ID:", token_ids)
print("Encoded input:", encoded_input)
```

```
config.json: 100% 483/483 [00:00<00:00, 42.0kB/s]
```

```
tokenizer_config.json: 100% 48.0/48.0 [00:00<00:00, 4.19kB/s]
```

```
vocab.txt: 100% 232k/232k [00:00<00:00, 5.38MB/s]
```

```
tokenizer.json: 100% 466k/466k [00:00<00:00, 17.2MB/s]
```

```
Tokeny: ['c', '##zes', '##to', 'jem', 'go', '##ude', '.']
```

```
Tokeny w formie ID: [1039, 11254, 3406, 24193, 2175, 12672, 1012]
```

```
Encoded input: {'input_ids': tensor([[ 101, 1039, 11254, 3406, 24193, 2175, 12672, 1012, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0, 0, 0]])}
```

Na co warto zwrócić uwagę?

- distilbert używa podobnego tokenizera, więc również mamy '##' w podziale słów
- Nie ma token_type_ids! distilbert ich nie używa

✓ Co kiedy mamy kilka tekstów?

```
tokenizer = AutoTokenizer.from_pretrained("bert-base-uncased")

text1 = "Czy lubisz ser?"
text2 = "Nigdy nie jadłem mozarelli"

encoded_pair = tokenizer(text1, text2, return_tensors="pt")
print("Encoded pair:", encoded_pair)
print("Token_type_ids:", encoded_pair['token_type_ids'])
```

```
Encoded pair: {'input_ids': tensor([[ 101, 1039, 9096, 11320, 18477, 2480, 14262, 1029, 102, 9152,
2290, 5149, 9152, 2063, 14855, 2094, 18818, 6633, 9587, 9057,
13348, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1]]), 'e
Token_type_ids: tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1]])
```

Na co warto zwrócić uwagę?

- Tutaj tokeny pochodzące z pierwszego zdania mają token_type_id = 0, a tokeny z drugiego zdania mają token_type_id = 1

✓ Padding

```
sentences = ["Idę kupić brie.", "Mój ulubiony ser to cheddar."]

# tokenizer z paddingiem i maksymalną długością batch
encoded_batch = tokenizer(sentences, padding=True, return_tensors="pt")
print("Encoded batch:", encoded_batch)
```

```
Encoded batch: {'input_ids': tensor([[ 101, 8909, 2063, 13970, 24330, 7987, 2666, 1012, 102, 0,
0, 0, 0],
[ 101, 9587, 3501, 17359, 12083, 3258, 2100, 14262, 2000, 18178,
7662, 1012, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0],
[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]]), 'attention_mask': tensor([[1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0],
[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1]])}
```

Na co warto zwrócić uwagę?

- input_ids będą uzupełnione 0 tam, gdzie brak tokenów w krótszym zdaniu.
- attention_mask pokaże, które tokeny są ważne (1) a które padding (0).

Kiedy używamy paddingu?

Mając wiele zdań w jednym batchu, wszystkie sekwencje muszą mieć ten sam rozmiar

✓ Części mowy

W przetwarzaniu języka naturalnego (NLP) często chcemy wyłuskać z tekstu określone fragmenty, np. **rzeczowniki**, **czasowniki**, czy **przymiotniki**. SpaCy umożliwia nam analizę składniową tekstu, a następnie tworzenie **filtrów** w oparciu o **części mowy (POS)** lub **inne cechy tokenów**.

Podstawowe części mowy w spaCy

Każdy token w tekście posiada atrybut `.pos_`, który określa jego część mowy. Najważniejsze przykłady:

POS	Znaczenie	Przykład
NOUN	Rzeczownik	"rower", "kot", "samochód"
PROPN	Rzeczownik własny (nazwa własna)	"Warszawa", "Apple"
VERB	Czasownik	"biega", "sprzedam"
ADJ	Przymiotnik	"nowy", "duży"
ADV	Przysłówek	"szybko", "bardzo"
NUM	Liczba	"1200", "13"
PRON	Zaimek	"ja", "ty"
DET	Określnik/rodzajnik	"ten", "ta"

Tworzenie prostych filtrów w spaCy

Możemy wykorzystać **Matcher** lub pętlę po tokenach, aby wyłuskać interesujące nas słowa.

```
!python -m spacy download pl_core_news_sm
import spacy
```

```
nlp = spacy.load("pl_core_news_sm")
text = "Bardzo lubię ser pleśniowy."
```

```
doc = nlp(text)
```

```
nouns = [token.text for token in doc if token.pos_ in ["NOUN", "PROPN"]]
print("Rzeczowniki:", nouns)
```

Collecting pl-core-news-sm==3.8.0

Downloading https://github.com/explosion/spacy-models/releases/download/pl_core_news_sm-3.8.0/pl_core_news_sm-3.8.0-py3-nc 20.2/20.2 MB 36.8 MB/s eta 0:00:00

✓ Download and installation successful

You can now load the package via `spacy.load('pl_core_news_sm')`

⚠ Restart to reload dependencies

If you are in a Jupyter or Colab notebook, you may need to restart Python in order to load all the package's dependencies. You can do this by selecting the 'Restart kernel' or 'Restart runtime' option.

Rzeczowniki: ['ser']

```
from spacy.matcher import Matcher
```

```
matcher = Matcher(nlp.vocab)
```

```
# Wzorzec: przymiotnik + rzeczownik
```

```
pattern = [{"POS": "NOUN"}, {"POS": "ADJ"}]
```

```
matcher.add("ADJ_NOUN", [pattern])
```

```
matches = matcher(doc)
```

```
for match_id, start, end in matches:
```

```
    span = doc[start:end]
```

```
    print("ADJ + NOUN:", span.text)
```

```
ADJ + NOUN: ser pleśniowy
```

Dzięki takim filtrom i częściom mowy możemy łatwo budować ekstraktory informacji z tekstów, np. ogłoszeń, nagłówków czy artykułów.

▼ Zadania

▼ Zadanie 1

1. Porównaj tokeny poniższych zdań wygenerowane przez 3 tokenizery:

- bert-base-uncased
- distilbert-base-uncased
- roberta-base

2. Sprawdź:

- Tokeny specjalne używane przez każdy model. Czy występują? Jakież?
- Czy padding został dodany? Jak wygląda attention_mask?
- Które modele używają token_type_ids

3. Uzupełnij tabelkę poniżej na podstawie wyników (jeśli jest problem z uzupełnieniem tabeli proszę słownie zapisać obserwacje)

```
#zadanie 1
```

```
texts = [
```

```
    "Kocham ser",
```

```
    "W czwartek idę do sklepu.",
```

```
    "Czy jutro będzie padać?"
```

```
]
```

```
# TODO - wyprintuj tokenizację powyższych tekstów
```

```
from transformers import AutoTokenizer
```

```
tokenizer = AutoTokenizer.from_pretrained('bert-base-uncased')
```

```
for text in texts:
```

```
    encoded_input = tokenizer(text, return_tensors = "pt")
```

```
    print(encoded_input)
```

```
{'input_ids': tensor([[ 101, 15259, 3286, 14262, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0]]), 'attention_mask':
```

```
{'input_ids': tensor([[ 101, 1059, 1039, 2480, 18367, 5937, 8909, 2063, 2079, 15315,
```

```
2571, 14289, 1012, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]]), 'attention_m
```

```
{'input_ids': tensor([[ 101, 1039, 9096, 18414, 13181, 2793, 14272, 11687, 6305, 1029,
102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 0]]), 'attention_mask': tensor([[1, 1, 1, 1, 1,
102]])}
```

```
tokenizer = AutoTokenizer.from_pretrained('distilbert-base-uncased')
```

```
for text in texts:
    encoded_input = tokenizer(text, return_tensors = "pt")
    print(encoded_input)
```

```
{'input_ids': tensor([[ 101, 15259, 3286, 14262, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0]]), 'attention_mask':
{'input_ids': tensor([[ 101, 1059, 1039, 2480, 18367, 5937, 8909, 2063, 2079, 15315,
2571, 14289, 1012, 102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]]), 'attention_m
{'input_ids': tensor([[ 101, 1039, 9096, 18414, 13181, 2793, 14272, 11687, 6305, 1029,
102]]), 'token_type_ids': tensor([[0, 0, 0, 0, 0, 0, 0, 0, 0, 0]]), 'attention_mask': tensor([[1, 1, 1, 1, 1,
102]])}
```

```
tokenizer = AutoTokenizer.from_pretrained('roberta-base')
```

```
for text in texts:
    encoded_input = tokenizer(text, return_tensors = "pt")
    print(encoded_input)
```

```
{'input_ids': tensor([[ 0, 530, 4306, 424, 6821, 2]]), 'attention_mask': tensor([[1, 1, 1, 1, 1, 1]])}
{'input_ids': tensor([[ 0, 771, 25198, 21660, 1951, 13561, 649, 27, 109, 2972,
459, 30738, 4, 2]]), 'attention_mask': tensor([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1]])}
{'input_ids': tensor([[ 0, 347, 5144, 1236, 1182, 1001, 741, 649, 27, 417,
14807, 181, 2095, 4807, 116, 2]]), 'attention_mask': tensor([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1]])}
```

Uzupełnij tabelę swoimi obserwacjami:

Model	Tokeny specjalne	Padding	Token_type_ids
Przykład	[nazwa tokenu] / NIE jeśli nie występują	Tak, jak zaznaczają? / Nie	Tak / Nie
BERT	101,102	NIE	TAK
DistilBERT	101,102	NIE	TAK
RoBERTa	0,2	NIE	NIE

▼ Zadanie 2

Teraz zrobimy zadanie z spaCy i jego Matcherem, który pozwala wyszukiwać wzorce w tekście na podstawie części mowy (POS tagging).

```
!pip install spacy
!python -m spacy download pl_core_news_sm
```

```
import spacy
from spacy.matcher import Matcher
```

```
nlp = spacy.load("pl_core_news_sm")
```

```
Requirement already satisfied: spacy in /usr/local/lib/python3.13/dist-packages (3.8.16)
Requirement already satisfied: spacy-legacy<3.1.0,>=3.0.11 in /usr/local/lib/python3.13/dist-packages (from spacy) (3.0.12)
Requirement already satisfied: spacy-loggers<2.0.0,>=1.0.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (1.0.5)
Requirement already satisfied: murmurhash<1.1.0,>=0.28.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (1.0.15)
Requirement already satisfied: cymem<2.1.0,>=2.0.2 in /usr/local/lib/python3.13/dist-packages (from spacy) (2.0.13)
Requirement already satisfied: preshed<3.1.0,>=3.0.2 in /usr/local/lib/python3.13/dist-packages (from spacy) (3.0.13)
Requirement already satisfied: thinc<8.4.0,>=8.3.12 in /usr/local/lib/python3.13/dist-packages (from spacy) (8.3.13)
Requirement already satisfied: wasabi<1.2.0,>=0.9.1 in /usr/local/lib/python3.13/dist-packages (from spacy) (1.1.3)
Requirement already satisfied: srsly<3.0.0,>=2.5.3 in /usr/local/lib/python3.13/dist-packages (from spacy) (2.5.4)
Requirement already satisfied: catalogue<2.1.0,>=2.0.6 in /usr/local/lib/python3.13/dist-packages (from spacy) (2.0.10)
Requirement already satisfied: weasel<2.0.0,>=1.0.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (1.0.0)
Requirement already satisfied: confection<2.0.0,>=1.3.2 in /usr/local/lib/python3.13/dist-packages (from spacy) (1.3.3)
Requirement already satisfied: typer<1.0.0,>=0.3.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (0.27.2)
Requirement already satisfied: click<9.0.0,>=8.2.1 in /usr/local/lib/python3.13/dist-packages (from spacy) (8.5.0)
Requirement already satisfied: tqdm<5.0.0,>=4.38.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (4.67.3)
Requirement already satisfied: numpy<=1.19.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (2.1.3)
Requirement already satisfied: requests<3.0.0,>=2.13.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (2.32.4)
Requirement already satisfied: pydantic<3.0.0,>=2.0.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (2.13.5)
Requirement already satisfied: Jinja2 in /usr/local/lib/python3.13/dist-packages (from spacy) (3.1.6)
Requirement already satisfied: setuptools in /usr/local/lib/python3.13/dist-packages (from spacy) (80.10.2)
Requirement already satisfied: packaging<=20.0 in /usr/local/lib/python3.13/dist-packages (from spacy) (26.3)
Requirement already satisfied: annotated-types<=0.6.0 in /usr/local/lib/python3.13/dist-packages (from pydantic<3.0.0,>=2.0.0)
Requirement already satisfied: pydantic-core==2.46.5 in /usr/local/lib/python3.13/dist-packages (from pydantic<3.0.0,>=2.0.0)
Requirement already satisfied: typing-extensions<=4.14.1 in /usr/local/lib/python3.13/dist-packages (from pydantic<3.0.0,>=2.0.0)
Requirement already satisfied: typing-inspection<=0.4.2 in /usr/local/lib/python3.13/dist-packages (from pydantic<3.0.0,>=2.0.0)
Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python3.13/dist-packages (from requests<3.0.0,>=2.13.0->spacy)
Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.13/dist-packages (from requests<3.0.0,>=2.13.0->spacy)
Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.13/dist-packages (from requests<3.0.0,>=2.13.0->spacy)
Requirement already satisfied: certifi<=2017.4.17 in /usr/local/lib/python3.13/dist-packages (from requests<3.0.0,>=2.13.0->spacy)
Requirement already satisfied: blis<1.4.0,>=1.3.0 in /usr/local/lib/python3.13/dist-packages (from thinc<8.4.0,>=8.3.12->spacy)
Requirement already satisfied: shellingham<=1.3.0 in /usr/local/lib/python3.13/dist-packages (from typer<1.0.0,>=0.3.0->spacy)
```

Requirement already satisfied: rich>=13.8.0 in /usr/local/lib/python3.13/dist-packages (from typer<1.0.0,>=0.3.0->spacy) (13.8.0)

Requirement already satisfied: annotated-doc>=0.0.2 in /usr/local/lib/python3.13/dist-packages (from typer<1.0.0,>=0.3.0->spacy) (0.0.2)

Requirement already satisfied: cloudpathlib>=0.7.0 in /usr/local/lib/python3.13/dist-packages (from weasel<2.0.0,>=1.0.0->spacy) (0.7.0)

Requirement already satisfied: smart-open>=5.2.1 in /usr/local/lib/python3.13/dist-packages (from weasel<2.0.0,>=1.0.0->spacy) (5.2.1)

Requirement already satisfied: httpx>=0.24.0 in /usr/local/lib/python3.13/dist-packages (from weasel<2.0.0,>=1.0.0->spacy) (0.24.0)

Requirement already satisfied: MarkupSafe>=2.0 in /usr/local/lib/python3.13/dist-packages (from jinja2->spacy) (3.0.3)

Requirement already satisfied: anyio in /usr/local/lib/python3.13/dist-packages (from httpx>=0.24.0->weasel<2.0.0,>=1.0.0->spacy) (4.0.0)

Requirement already satisfied: httpcore==1.* in /usr/local/lib/python3.13/dist-packages (from httpx>=0.24.0->weasel<2.0.0,>=1.0.0->spacy) (1.0.7)

Requirement already satisfied: h11>=0.16 in /usr/local/lib/python3.13/dist-packages (from httpcore==1.*->httpx>=0.24.0->weasel<2.0.0,>=1.0.0->spacy) (0.14.0)

Requirement already satisfied: markdown-it-py>=2.2.0 in /usr/local/lib/python3.13/dist-packages (from rich>=13.8.0->typer<1.0.0,>=0.3.0->spacy) (3.0.0)

Requirement already satisfied: pygments<3.0.0,>=2.13.0 in /usr/local/lib/python3.13/dist-packages (from rich>=13.8.0->typer<1.0.0,>=0.3.0->spacy) (2.18.0)

Requirement already satisfied: wrapt in /usr/local/lib/python3.13/dist-packages (from smart-open>=5.2.1->weasel<2.0.0,>=1.0.0->spacy) (1.17.0)

Requirement already satisfied: mdurl~=0.1 in /usr/local/lib/python3.13/dist-packages (from markdown-it-py>=2.2.0->rich>=13.8.0->typer<1.0.0,>=0.3.0->spacy) (0.1.2)

Collecting pl-core-news-sm==3.8.0

Downloading https://github.com/explosion/spacy-models/releases/download/pl_core_news_sm-3.8.0/pl_core_news_sm-3.8.0-py3-none-any.whl 20.2/20.2 MB 31.7 MB/s eta 0:00:00

✓ Download and installation successful

You can now load the package via `spacy.load('pl_core_news_sm')`

⚠ Restart to reload dependencies

If you are in a Jupyter or Colab notebook, you may need to restart Python in order to load all the package's dependencies. You can do this by selecting the 'Restart kernel' or 'Restart runtime' option.

```
ads = [
    "Sprzedam rower górski za 1200 zł",
    "Do kupienia laptop Dell 3500 PLN",
    "Oferuję kanapę w dobrym stanie, cena 800 zł",
    "Sprzedam smartfon iPhone 13 za 4000 zł",
    "Na sprzedaż samochód Toyota Corolla, cena 15000 zł"
]
```

```
# TODO - przygotuj filtry
pattern_price = [{"IS_DIGIT": True}, {"LOWER": {"IN": ["zł", "pln"]}}]
matcher = Matcher(nlp.vocab)
matcher.add("price", [pattern_price])

for ad in ads:
    doc = nlp(ad)
    matches = matcher(doc)
    print(f"\n🚀 Ogłoszenie: {ad}")

    item = None

    for token in doc:
        if token.pos_ == "VERB": #szukamy po czesci mowy
            for child in token.children:
                if child.dep_ in ("obj", "obl") and child.pos_ == "NOUN": #szukamy rzeczownika ktory jest dopełnieniem lub o
                    item = child.lemma_ #lemma_ zwraca forme podstawowa
                    break

    if item:
        break

    if not item:
        for i, token in enumerate(doc):
            if token.text.lower() in ("sprzedaż", "kupienia"):
                for right in doc[i + 1 : i + 4]: #patrzmy na trzy nastepne tokeny po sprzedaz albo kupienia
                    if right.pos_ == "NOUN":
                        item = right.lemma_
                        break

                if item:
                    break

    if item:
        print(f"Przedmiot: {item}")

    for match_id, start, end in matches:
        span = doc[start:end]
        if nlp.vocab.strings[match_id] == "price":
            print(f"Cena: {span.text}")
```

🚀 Ogłoszenie: Sprzedam rower górski za 1200 zł
Przedmiot: rower
Cena: 1200 zł

🚀 Ogłoszenie: Do kupienia laptop Dell 3500 PLN
Przedmiot: laptop
Cena: 3500 PLN

🚀 Ogłoszenie: Oferuję kanapę w dobrym stanie, cena 800 zł
Przedmiot: kanapa
Cena: 800 zł

✦ Ogłoszenie: Sprzedam smartfon iPhone 13 za 4000 zł
Przedmiot: smartfon
Cena: 4000 zł

✦ Ogłoszenie: Na sprzedaż samochód Toyota Corolla, cena 15000 zł
Przedmiot: samochód
Cena: 15000 zł